

**GLOBAL PROJECT – SANDRA CONCA GÓMEZ**

**ÍNDICE**

**Contenido**

1.	INTRODUCCIÓN .....	1
2.	CONEXIÓN A POWER BI MEDIANTE SQL SERVER.....	2
3.	DESCRIPCIÓN DE LAS TABLAS CONTENIDAS EN LA BBDD .....	3
4.	CASO DE USO: ANÁLISIS DE ROTACIÓN DE PRODUCTOS – OPTIMIZACIÓN DE CATÁLOGO.....	4
5.	IA: SEGMENTACIÓN MEDIANTE ALGORITMO K-MEANS.....	6
6.	PROCESO ETL.....	11
7.	MODELO DE DATOS EN POWER BI.....	15
8.	CUADRO DE MANDO EN POWER BI .....	19
9.	CONTRIBUCIÓN DEL DASHBOARD A LA TOMA DE DECISIONES Y ANÁLISIS DE RESULTADOS.....	25
10.	CONCLUSIÓN.....	27

## 1. INTRODUCCIÓN

En el contexto actual de la industria, la transformación digital y la adopción de una cultura basada en datos son factores clave para garantizar la competitividad y la eficiencia operativa de las organizaciones. Las empresas industriales, como IEBS Manufacturing, enfrentan el reto de integrar, analizar y explotar grandes volúmenes de información generados por sus sistemas de gestión empresarial (ERP), con el fin de tomar decisiones más rápidas, informadas y alineadas con los objetivos estratégicos.

IEBS Manufacturing es una empresa del sector del metal, con sede en España, dedicada a la adquisición de materias primas, la transformación de materiales y la comercialización de productos de valor añadido. A pesar de contar con una base de datos rica en información transaccional y logística, no disponía de un sistema de inteligencia de negocio que permitiera explotar dichos datos de forma eficaz para mejorar la toma de decisiones. En este contexto, el presente proyecto tiene como objetivo principal diseñar e implementar una solución de análisis avanzada basada en Power BI, que permita convertir los datos históricos de la empresa en conocimiento útil para la toma de decisiones.

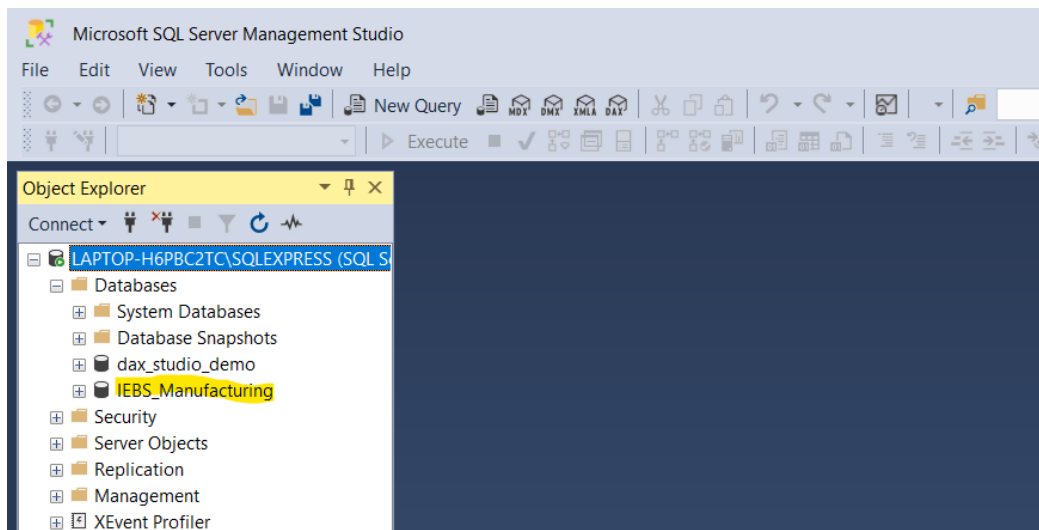
El proyecto se estructura en torno a un caso de uso concreto: el análisis de la rotación de productos y la optimización del catálogo comercial. Para abordar este reto, se ha diseñado un flujo completo de trabajo que incluye la restauración de la base de datos en SQL Server, su conexión a Power BI, la preparación y transformación de los datos mediante un proceso ETL, el desarrollo de medidas clave (KPIs), la aplicación de algoritmos de inteligencia artificial (clustering no supervisado con K-means) y la construcción de un cuadro de mando interactivo que integra todos los resultados.

Este documento presenta de forma sistemática todas las etapas del proyecto, desde el diseño del modelo de datos hasta la interpretación final de los resultados, con el fin de ofrecer una solución práctica que demuestre el valor de la analítica de datos aplicada a un entorno industrial real.

## 2. CONEXIÓN A POWER BI MEDIANTE SQL SERVER

Para el desarrollo del proyecto, se ha proporcionado un archivo con extensión .bak, correspondiente a una copia de seguridad de una base de datos en Microsoft SQL Server. Este archivo contiene la información de la empresa IEBS Manufacturing, estructurada dentro de un sistema ERP (Navision Dynamics).

El primer paso ha consistido en la restauración del archivo .bak dentro de una instancia de Microsoft SQL Server Management Studio (SSMS). Esta operación se ha llevado a cabo mediante la funcionalidad de restauración de base de datos, seleccionando la opción "Dispositivo" en el asistente de restauración y localizando el archivo .bak correspondiente. Una vez completada la restauración, la base de datos quedó accesible bajo el nombre IEBS\_Manufacturing.



Posteriormente, para proceder al análisis de los datos mediante Power BI, se ha establecido una conexión directa con la instancia de SQL Server. Desde Power BI Desktop, se seleccionó la opción "Obtener datos" - "SQL Server", e introduciendo el nombre del servidor local se han importado las tablas relevantes al modelo de datos.

### 3. DESCRIPCIÓN DE LAS TABLAS CONTENIDAS EN LA BBDD

La base de datos restaurada contiene múltiples tablas extraídas del ERP, de las cuales se han seleccionado aquellas necesarias para realizar el análisis de negocio. A continuación, se describen las principales tablas utilizadas en el modelo:

- **Customer:** contiene información relativa a los clientes de la empresa, incluyendo identificadores únicos, ubicación geográfica, condiciones de pago y fecha de alta.
- **Vendor:** almacena los datos de los proveedores, con estructura similar a la tabla de clientes. Contiene campos como nombre, código de país, ciudad, y condiciones comerciales.
- **Item:** recoge el catálogo de productos, incluyendo identificadores, atributos técnicos y referencias internas de planificación y producción.
- **Sales\_Header:** agrupa los documentos de venta emitidos por la empresa, incluyendo fechas de pedido y contabilización, identificadores de cliente, tipo de documento y moneda utilizada.
- **Sales\_Invoice\_Line:** tabla de detalle de facturas, en la que cada fila representa una línea individual de venta. Contiene información clave para el análisis financiero, como precio unitario, cantidad, coste unitario y valor neto.
- **Sales\_Shipment\_Header:** tabla relacionada con los envíos de productos, que permite establecer relaciones con los documentos de venta a través de identificadores comunes.
- **Country\_Region:** tabla de referencia que permite normalizar los códigos de país y asignarlos a clientes y proveedores.
- **Calendario** (tabla calculada): se trata de una tabla generada mediante DAX en Power BI, construida a partir del rango de fechas presente en los datos de ventas.

## 4. CASO DE USO: ANÁLISIS DE ROTACIÓN DE PRODUCTOS – OPTIMIZACIÓN DE CATÁLOGO

Uno de los principales retos que enfrentan las empresas industriales que operan bajo un modelo de producción-distribución, como IEBS Manufacturing, es la gestión eficiente del catálogo de productos. Dado que la empresa produce, transforma y comercializa artículos clasificados en distintas familias (como productos elaborados, materias primas o componentes electrónicos), resulta fundamental conocer con precisión el comportamiento de cada producto en términos de ventas, coste, rentabilidad y demanda a lo largo del tiempo.

El caso de uso seleccionado para este proyecto se centra en la **identificación de patrones de rotación de producto** con el objetivo de segmentar el catálogo y facilitar la toma de decisiones estratégicas relacionadas con:

- Eliminación o sustitución de productos de baja rotación.
- Priorización de artículos clave en campañas de venta y planificación productiva.
- Optimización de stock y logística mediante una mejor comprensión del ciclo de vida de los productos.

Este enfoque no solo atiende a necesidades operativas inmediatas, sino que además sienta las bases para avanzar hacia una gestión basada en datos (data-driven), alineada con los principios de mejora continua y eficiencia empresarial.

### I. Metodología para abordar el caso de uso

Para abordar este problema, se ha diseñado una solución en varias etapas, partiendo de la explotación de la base de datos hasta la aplicación de técnicas de inteligencia artificial. A continuación, se describen las fases consideradas:

#### a) Preparación y análisis exploratorio de los datos

Una vez importadas y relacionadas las tablas principales en Power BI, se procedió al análisis exploratorio de los datos (EDA), con el objetivo de comprender la estructura del negocio, los flujos de ventas y la relación entre productos, clientes

y fechas. Se utiliza *Python* como lenguaje para este análisis mediante la herramienta *Google Colaboratory*.

### **b) Clasificación de productos mediante clustering**

Dado que no existía una segmentación explícita del catálogo más allá de la codificación alfanumérica, se propuso un modelo de clasificación no supervisada basado en **algoritmos de agrupamiento (clustering)**. Se aplicó la técnica de **K-means**, considerando como variables de entrada:

- Total de ventas por producto
- Total de unidades vendidas
- Coste total asociado
- Número de clientes distintos que han adquirido cada producto

El objetivo era obtener grupos homogéneos de productos según su comportamiento comercial. La técnica del codo fue utilizada para determinar el número óptimo de clústeres.

### **c) Implementación de análisis visual en Power BI**

Tras asignar a cada producto un clúster resultante, se incorporó esta segmentación al modelo de Power BI mediante la importación de los resultados del clustering realizados en Python. A partir de esta información, se diseñaron visualizaciones interactivas que permiten a los usuarios analizar el rendimiento de cada grupo de productos desde distintas perspectivas: temporal, geográfica y por tipo de cliente.

### **d) Capacitación para la toma de decisiones**

El resultado de este caso de uso es la construcción de un **cuadro de mando completo**, capaz de mostrar dinámicamente el comportamiento de los productos agrupados, permitiendo tomar decisiones informadas sobre mantenimiento, promoción o eliminación del catálogo.

## 5. IA: SEGMENTACIÓN MEDIANTE ALGORITMO K-MEANS

Como parte de la solución propuesta al caso de uso definido se ha implementado un modelo de aprendizaje automático no supervisado con el fin de clasificar los productos según su comportamiento comercial. En concreto, se empleó el algoritmo de **K-means clustering**, una técnica frecuentemente utilizada para la agrupación de elementos en función de sus características cuantitativas.

Este enfoque ha permitido **identificar patrones de comportamiento** entre productos sin necesidad de etiquetas o categorías predefinidas, y ha facilitado la creación de una segmentación dinámica del catálogo útil para el análisis de negocio.

### I. Preparación de los datos para el modelo

El proceso comienza con la exportación desde Power BI de una tabla agregada por producto, en la que se incluían los siguientes indicadores calculados (posteriormente se explicará el modelo creado en Power BI junto con las medidas creadas con DAX):

- **Total de ventas** (TotalVentas)
- **Total de unidades vendidas** (UnidadesVendidas)
- **Coste total** (TotalCoste)
- **Cientes únicos** (ClientesUnicos)

Dicha tabla se ha exportado en formato .csv y se ha cargado posteriormente en un entorno de desarrollo en *Google Colab*, utilizando *Python* y las librerías de análisis de datos *pandas*, *matplotlib*, *scikit-learn* y *seaborn*.

Antes de proceder con la modelización, se ha realizado un preprocesamiento de los datos que incluyó:

- Normalización de las variables mediante *StandardScaler*, con el fin de evitar la influencia desproporcionada de las variables con mayor magnitud.
- Análisis visual de correlaciones para comprobar la coherencia de las variables de entrada.

- Detección y eliminación de valores atípicos si era necesario.

## **CÓDIGO EN PYTHON**

```
import pandas as pd
```

```
from sklearn.preprocessing import StandardScaler
```

```
from sklearn.cluster import KMeans
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
# Cargar el CSV exportado desde Power BI
```

```
df = pd.read_csv('/content/data.csv')
```

```
# Seleccionamos solo las columnas numéricas que usaremos en el clustering
```

```
variables = ["Suma de TotalVentas", "Suma de TotalCoste", "Suma de  
UnidadesVendidas", "Suma de ClientesUnicos"]
```

```
X = df[variables]
```

```
# Estandarizar (muy importante para K-means)
```

```
scaler = StandardScaler()
```

```
X_scaled = scaler.fit_transform(X)
```

```
inertia = []
```

```
# Probar distintos valores de k (número de clusters)
```

```
for k in range(1, 11):
```

```
    km = KMeans(n_clusters=k, random_state=42)
```

```
    km.fit(X_scaled)
```

```
    inertia.append(km.inertia_)
```



## II. Selección del número óptimo de clústeres


Uno de los aspectos fundamentales del algoritmo K-means es la elección del número de clústeres  $k$ . Para determinar este valor de forma óptima, se utilizó el **método del codo (elbow method)**, que consiste en ejecutar el modelo con distintos valores de  $k$  y graficar la evolución de la inercia (suma de las distancias cuadradas a los centroides) en función del número de grupos.

El análisis del gráfico mostró un punto de inflexión claro en  $k = 4$ , lo que indicaba que aumentar el número de clústeres más allá de ese valor no producía mejoras sustanciales en la cohesión interna de los grupos. Por tanto, se seleccionó  $k = 4$  como número final de agrupaciones.

### CÓDIGO EN PYTHON

*# Grafico curva de codo*

```
plt.figure(figsize=(8,5))  
  
plt.plot(range(1, 11), inertia, marker='o')  
  
plt.title('Método del codo')  
  
plt.xlabel('Número de clusters (k)')  
  
plt.ylabel('Inercia')  
  
plt.grid()  
  
plt.show()
```



```
# Elegimos un número de clusters (por ejemplo 4)
```

```
kmeans = KMeans(n_clusters=4, random_state=42)
```

```
df["Cluster"] = kmeans.fit_predict(X_scaled)
```

```
# Revisar cómo quedaron los productos agrupados
```

```
df.groupby("Cluster")[variables].mean()
```

### III. Entrenamiento del modelo y asignación de clústeres

Una vez determinado  $k = 4$ , se entrenó el modelo K-means con las variables seleccionadas y se asignó a cada producto un clúster en función de su perfil de comportamiento. Los resultados fueron los siguientes:

- **Clúster 0:** Productos de baja rotación y escasas ventas.
- **Clúster 1:** Productos con comportamiento intermedio en cuanto a ventas y clientes.
- **Clúster 2:** Productos clave con alta concentración de ventas y demanda.
- **Clúster 3:** Productos de alta facturación con bajo número de unidades vendidas, posiblemente de alto valor unitario.

La interpretación de los clústeres fue validada mediante visualizaciones de dispersión y gráficos de barras, en los que se representaron las ventas y el coste por grupo de producto.

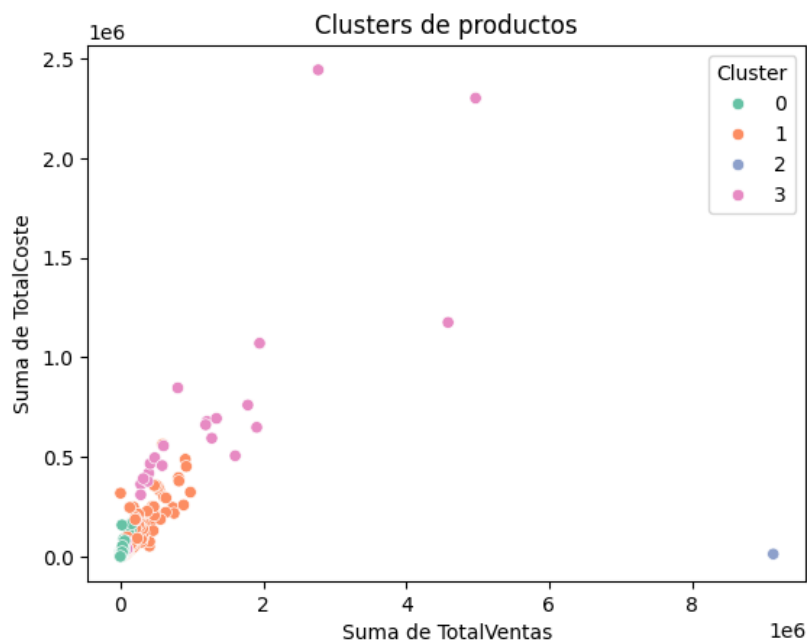
### CÓDIGO EN PYTHON

```
# Representación bidimensional con dos variables clave
```

```
sns.scatterplot(data=df, x="Suma de TotalVentas", y="Suma de TotalCoste",  
hue="Cluster", palette="Set2")
```

```
plt.title("Clusters de productos")
```

```
plt.show()
```



```
df["ClusterNombre"] = df["Cluster"].map({
    0: "Baja rotación",
    1: "Catálogo medio",
    2: "Muy rentable (revisar)",
    3: "Alta rotación / Clave"
})
```

#### IV. Integración de los resultados en Power BI

Una vez finalizado el entrenamiento y etiquetado de productos, el archivo .csv con los resultados (producto y clúster asignado) se ha importado de nuevo a Power BI y conectado al modelo de datos mediante relaciones basadas en el identificador de producto.

Esta integración permitió incorporar el campo **ClusterNombre** como nueva dimensión de análisis en todas las visualizaciones del dashboard, posibilitando:

- La comparación entre clústeres en términos de ventas, beneficio, geografía o clientes.

- La generación de filtros personalizados por grupo de productos.
- La evaluación estratégica del catálogo desde un enfoque basado en datos.

## 6. PROCESO ETL

La correcta preparación de los datos constituye un elemento esencial para garantizar la calidad del análisis, la fiabilidad de los resultados y la utilidad de las visualizaciones. En este proyecto, se ha desarrollado un proceso ETL (Extract, Transform, Load) a nivel macro con el objetivo de estructurar los datos disponibles en la base de datos de IEBS Manufacturing, transformar la información relevante para el análisis y cargarla de forma eficiente en el entorno de Power BI.

El proceso ETL ha sido diseñado de forma modular, respetando las buenas prácticas de tratamiento de datos en entornos de business intelligence, y adaptado a la naturaleza relacional de las tablas provenientes del sistema ERP Navision Dynamics.

### I. Extracción

La fase de extracción consistió en la conexión a la base de datos SQL Server restaurada a partir del archivo .bak original. Desde Power BI se accedió a las siguientes tablas principales:

- Customer
- Vendor
- Item
- Sales\_Header
- Sales\_Invoice\_Line
- Sales\_Shipment\_Header
- Country\_Region

Cada una de estas tablas fue importada mediante el conector nativo de Power BI para SQL Server, utilizando el modo de conectividad **Importar**, que permite cargar los datos en memoria y mejorar el rendimiento de las visualizaciones y cálculos posteriores.

## **II. Transformación**

La fase de transformación no se limitó a la limpieza y estructuración de los datos, sino que también incluyó la **definición de lógica analítica** y la creación de indicadores clave para el análisis del negocio. Esta etapa fue fundamental para convertir los datos operativos del ERP en información relevante para la toma de decisiones.

Las principales transformaciones realizadas fueron las siguientes:

### **a) Limpieza y estructuración de datos**

- Eliminación de columnas no relevantes, unificación de nomenclaturas y estandarización de formatos.
- Conversión de campos de texto a numéricos o de fecha cuando fue necesario para garantizar la correcta operación de filtros y agregaciones.
- Verificación de duplicidades y control de calidad sobre campos clave como identificadores de producto, fechas y relaciones cliente-producto.

### **b) Enriquecimiento de datos**

- **Derivación de atributos temporales** a partir de la columna Order Date, tales como:
  - Año (Year)
  - Número de mes (Monthnumber)
  - Nombre de mes (MonthNameShort)
  - Año y mes concatenado (YearMonth)
  - Trimestre (Quarter)

- **Clasificación de productos** en función de su código mediante una expresión DAX que distingue el tipo de producto (Elaborado, Plástico, etc.) según el prefijo del campo No\_.

```
// Clasificación de tipo de producto
"TipoProducto",
SWITCH(TRUE(),
    LEFT('Sales_Invoice_Line'[No_], 2) = "EL", "Elaborado",
    LEFT('Sales_Invoice_Line'[No_], 1) = "P", "Plástico",
    LEFT('Sales_Invoice_Line'[No_], 2) = "DE", "Dispositivo
Electrónico",
    LEFT('Sales_Invoice_Line'[No_], 2) = "SE", "Semi-
Elaborado",
    LEFT('Sales_Invoice_Line'[No_], 2) = "MP", "Materia
Prima",
    "Otro"
)
```

### c) Creación de indicadores y medidas DAX

Se desarrolló una **tabla de medidas específica** (denominada KPIs) para centralizar la lógica analítica y facilitar el mantenimiento del modelo. Entre las principales medidas calculadas se incluyen:

- **Medidas de ventas y costes:**

Total Ventas = `SUM('Sales_Invoice_Line'[Line Amount])`

Total Coste =

```
SUMX (
    'Sales_Invoice_Line',
    'Sales_Invoice_Line'[Quantity] * 'Sales_Invoice_Line'[Unit
Cost (LCY)]
)
```

Ganancias = [Total Ventas] - [Total Coste]

- **Medidas de clientes y volumen:**

Cientes Únicos = `DISTINCTCOUNT('Customer'[No_])`

Unidades Vendidas = `SUM('Sales_Invoice_Line'[Quantity])`

Ticket Medio Cliente = `DIVIDE([Total Ventas], [Clientes Únicos])`

- **Medidas temporales:**

Ventas YTD = `TOTALYTD([Total Ventas], 'Calendario'[Date])`

Ventas LY = `CALCULATE([Total Ventas], SAMEPERIODLASTYEAR('Calendario'[Date]))`

Variación Y/Y = [Total Ventas] - [Ventas LY]

Estas medidas se diseñaron para ser reutilizables en las distintas visualizaciones y se integraron en una estructura lógica que facilita el análisis transversal por producto, cliente, clúster y periodo.

#### **d) Integración de segmentaciones avanzadas**

Además de los filtros tradicionales por cliente o tipo de producto, se incorporaron segmentaciones dinámicas mediante:

- **Clústeres de producto** generados por el modelo de inteligencia artificial, integrados como una dimensión adicional (ClusterNombre).
- **Segmentadores temporales** basados en la tabla calendario, permitiendo seleccionar años, trimestres y meses de forma intuitiva.

- **Filtros por geografía y zona de venta** a partir de los datos de localización de clientes (ciudad, país/región).

### III. Carga

Una vez finalizadas las transformaciones, los datos fueron cargados al modelo de Power BI, donde se definieron las relaciones entre las tablas mediante un modelo estrella parcialmente normalizado. Desde este modelo se procedió a:

- La creación de medidas DAX para calcular KPIs clave (ventas, coste, beneficio, ticket medio, clientes únicos, entre otros).
- La implementación de visualizaciones interactivas (mapas, gráficos de líneas, tablas dinámicas, etc.).
- La construcción del cuadro de mando completo, incorporando segmentadores y filtros de usuario por tipo de producto, clúster y periodo temporal.

Este proceso ETL permitió consolidar la información dispersa en la base de datos del ERP y transformarla en un modelo estructurado y analíticamente eficiente, capaz de responder a los objetivos del caso de uso definido.

## 7. MODELO DE DATOS EN POWER BI

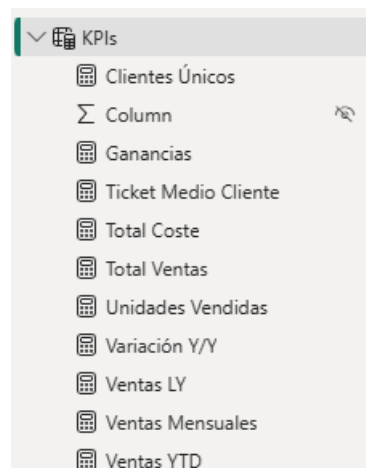
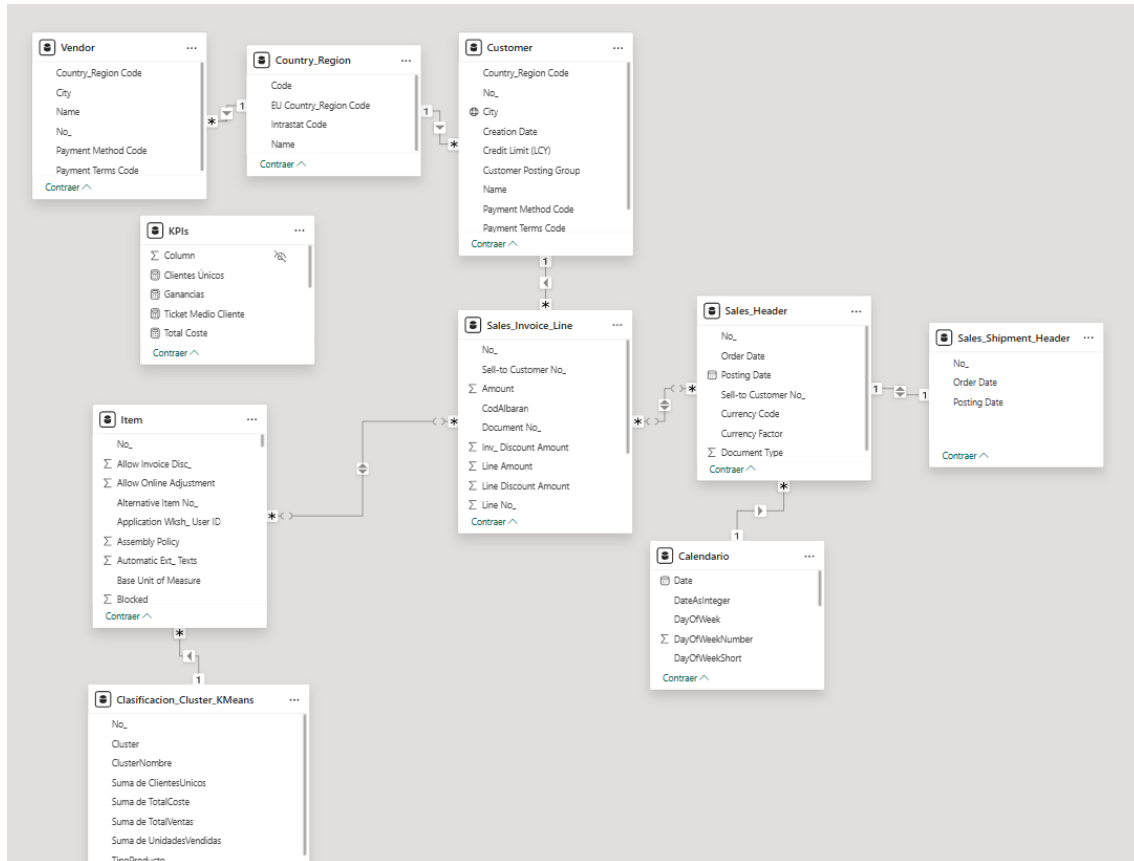
Una vez realizada la extracción y transformación de los datos, se procede a la creación del modelo de datos en Power BI. El objetivo principal es construir una estructura relacional que permita la navegación eficiente entre entidades clave del negocio y la realización de análisis multidimensionales.

El modelo de datos se estructura a partir de las principales tablas extraídas del sistema ERP, junto con elementos derivados como la tabla de medidas (KPIs), la tabla de calendario (Calendario) y la tabla resultante del modelo de clustering (Clasificación\_Cluster\_KMeans). Estas entidades fueron relacionadas entre sí en base a campos comunes, estableciendo un modelo de tipo **estrella**, adecuado para tareas de análisis y visualización.



## I. Estructura y relaciones

En la siguiente imagen se muestra el diagrama de relaciones generado en Power BI, el cual ilustra la estructura del modelo de datos final.



## Administrar relaciones



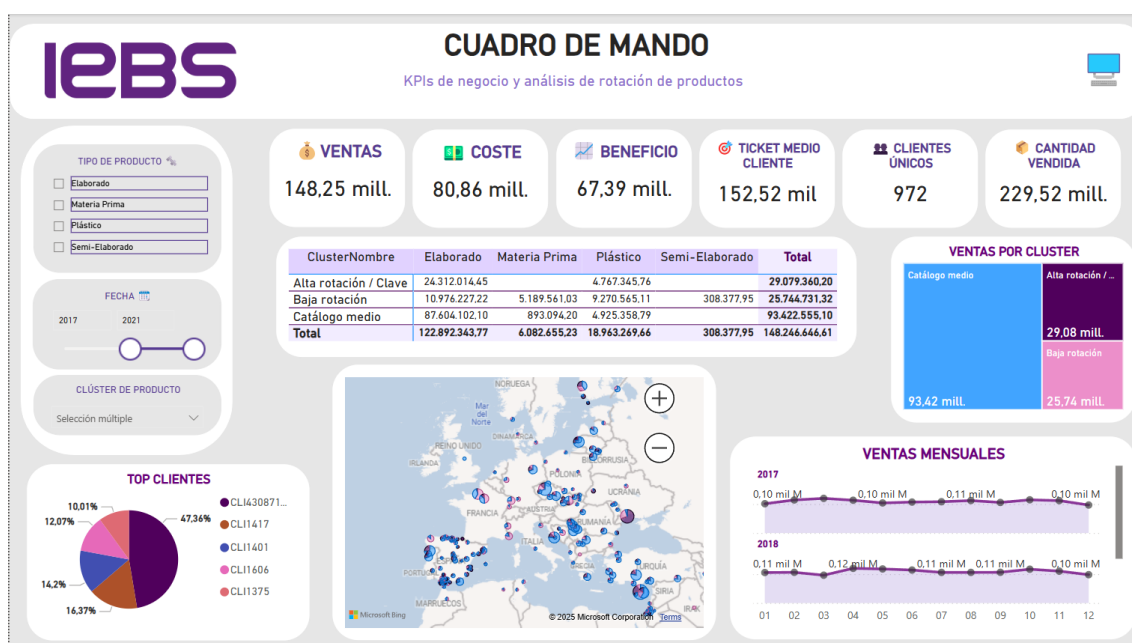
+ Nueva relación		⚡ Detección automática		✎ Editar		🗑 Eliminar		≡ Filtro	
<input type="checkbox"/>	Desde: tabla (columna) ↑	Relación	A: tabla (columna)	Estado					
<input type="checkbox"/>	Customer (Country_Region Co...	* — ◀ — 1	Country_Region (Code)	Activo	...				
<input type="checkbox"/>	Item (No_)	* — ▶ — *	Sales_Invoice_Line (No_)	Activo	...				
<input type="checkbox"/>	Item (No_)	* — ◀ — 1	Clasificacion_Cluster_KMeans (...)	Activo	...				
<input type="checkbox"/>	Sales_Header (No_)	1 — ▶ — 1	Sales_Shipment_Header (No_)	Activo	...				
<input type="checkbox"/>	Sales_Header (Order Date)	* — ◀ — 1	📅 Calendario (Date)	Activo	...				
<input type="checkbox"/>	Sales_Invoice_Line (Sell-to Cus...	* — ◀ — 1	Customer (No_)	Activo	...				
<input type="checkbox"/>	Sales_Invoice_Line (Sell-to Cus...	* — ▶ — *	Sales_Header (Sell-to Custome...	Activo	...				
<input type="checkbox"/>	Vendor (Country_Region Code)	* — ◀ — 1	Country_Region (Code)	Activo	...				

A continuación, se describen las entidades más relevantes y sus vínculos:

- **Sales\_Invoice\_Line:** tabla central del modelo, contiene el detalle de cada línea de factura de venta. Se relaciona con:
  - Customer mediante el campo Sell-to Customer No\_
  - Sales\_Header mediante el campo Document No\_
  - Item mediante el campo No\_
  - Clasificación\_Cluster\_KMeans mediante el campo No\_, correspondiente al identificador del producto
- **Sales\_Header:** tabla de cabecera de ventas, que aporta información de fechas y clientes. Se conecta a:
  - Sales\_Invoice\_Line (relación muchos-a-uno)
  - Calendario, mediante la relación con el campo Order Date, lo que permite una correcta segmentación temporal

- **Customer:** contiene los datos demográficos y comerciales de los clientes. Se relaciona con Sales\_Invoice\_Line y Sales\_Header, actuando como dimensión clave en el análisis de comportamiento comercial.
- **Vendor y Country\_Region:** tablas auxiliares para análisis relacionados con proveedores y geografía. Aunque no se utilizaron como parte del caso de uso principal, se conservaron en el modelo por su valor potencial en análisis complementarios.
- **Item:** tabla de productos, relacionada con Sales\_Invoice\_Line y con la tabla de clasificación de clústeres. Contiene atributos técnicos que permiten ampliar el análisis a nivel de catálogo.
- **Clasificación\_Cluster\_KMeans:** tabla importada desde Python, con los resultados del algoritmo de clustering. Esta tabla incluye, para cada producto, el clúster asignado y variables agregadas que sirvieron de entrada al modelo (ventas, clientes, coste, unidades vendidas).
- **Calendario:** tabla calculada en Power BI mediante DAX, construida con la función CALENDAR en base al rango de fechas de Sales\_Header[Order Date]. Permite realizar segmentaciones temporales por año, mes, trimestre y día de la semana, así como calcular medidas temporales como acumulados (YTD) o comparaciones interanuales (LY).
- **KPIs:** tabla de medidas centralizadas, construida exclusivamente con medidas DAX, lo que mejora la organización del modelo y su mantenimiento. Esta tabla no se relaciona directamente con otras entidades, ya que sus medidas se calculan en contexto dinámico a partir de las relaciones existentes.

## 8. CUADRO DE MANDO EN POWER BI



El resultado final del proceso de análisis y modelado de datos se materializó en la construcción de un **cuadro de mando interactivo**, diseñado para ofrecer una visión integral y dinámica del comportamiento comercial de IEBS Manufacturing. Este dashboard permite al usuario empresarial explorar, filtrar y segmentar la información según distintas dimensiones, facilitando así la toma de decisiones estratégicas y operativas basadas en datos.

La figura que se muestra a continuación representa la vista principal del cuadro de mando. A continuación, se describen los elementos visuales utilizados, así como la lógica detrás de su selección y disposición.

### I. Segmentadores (slicers)

En la parte izquierda del cuadro de mando se han incluido tres segmentadores clave:

- **Tipo de producto:** permite al usuario filtrar las visualizaciones por familia de producto (Elaborado, Materia Prima, Plástico, Semi-Elaborado), categorizadas a partir de una lógica basada en el código del producto.
- **Rango de fechas:** selector temporal con escala entre años, que permite delimitar el periodo de análisis. Este filtro está conectado a la tabla de

calendario y permite explorar tanto evoluciones temporales como valores agregados.

- **Clúster de producto:** segmentador derivado del modelo de inteligencia artificial, que permite filtrar los productos por su grupo de rotación (alta rotación, baja rotación, catálogo medio). Este filtro es esencial para el caso de uso del proyecto.

La presencia de estos filtros garantiza que todos los elementos del dashboard se comporten de forma dinámica y adaptativa al análisis deseado por el usuario.

The image shows a vertical filter panel with three distinct sections, each with a title and a set of controls:

- TIPO DE PRODUCTO**: Features a title with a small icon and four checkboxes, each followed by a text input field. The options are: ☐ Elaborado, ☐ Materia Prima, ☐ Plástico, and ☐ Semi-Elaborado.
- FECHA**: Features a title with a calendar icon and a date range selector. It shows the years 2017 and 2021 with a horizontal line and two circular handles in between.
- CLÚSTER DE PRODUCTO**: Features a title and a dropdown menu. The dropdown is currently set to "Selección múltiple" and has a downward arrow icon.


## II. Indicadores clave (KPIs)

En la parte superior central del panel se presentan seis indicadores clave de rendimiento:

- **Ventas**
- **Coste**
- **Beneficio**
- **Ticket medio por cliente**

- **Clientes únicos**
- **Cantidad vendida**

Estos indicadores han sido diseñados como visualizaciones tipo **tarjeta** para facilitar su lectura inmediata y destacar la magnitud de las cifras agregadas. Representan los ejes principales del análisis económico de la empresa y permiten obtener una fotografía general del negocio en cualquier periodo y contexto de filtro.



### III. Tabla cruzada de ventas por clúster y tipo de producto

En la parte central del panel se ha incorporado una **matriz de doble entrada**, que cruza:

- En filas: los clústeres generados por el algoritmo K-means (Alta rotación, Baja rotación, Catálogo medio).
- En columnas: las categorías de producto (Elaborado, Materia Prima, Plástico, Semi-Elaborado).

Esta tabla proporciona un análisis detallado de la distribución de las ventas, permitiendo identificar qué tipo de productos están sobrerrepresentados en cada clúster, y facilitando así decisiones relacionadas con optimización de catálogo o priorización comercial.

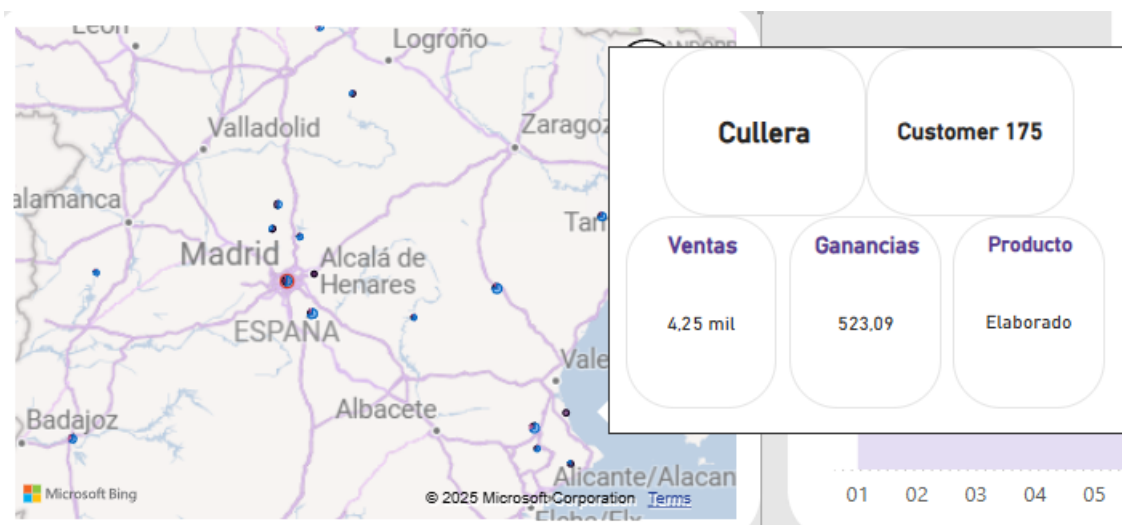
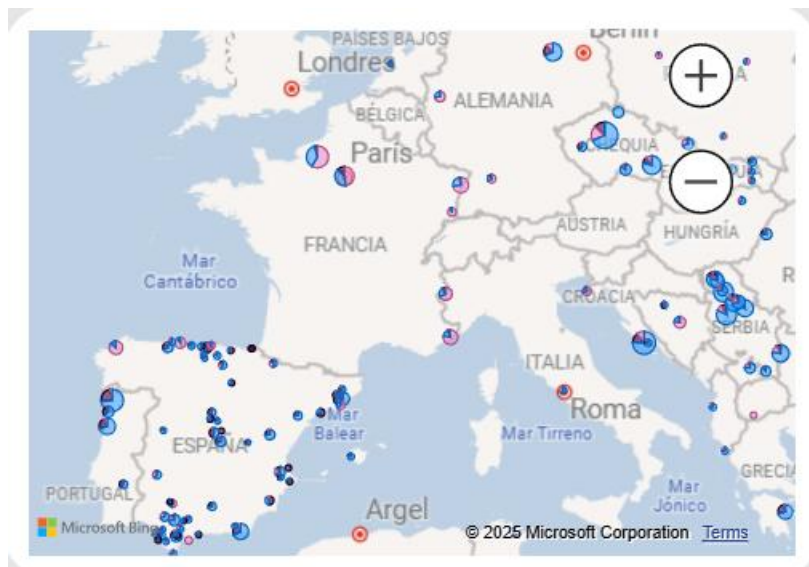
ClusterNombre	Elaborado	Materia Prima	Plástico	Semi-Elaborado	Total
Alta rotación / Clave	24.312.014,45		4.767.345,76		29.079.360,20
Baja rotación	10.976.227,22	5.189.561,03	9.270.565,11	308.377,95	25.744.731,32
Catálogo medio	87.604.102,10	893.094,20	4.925.358,79		93.422.555,10
<b>Total</b>	<b>122.892.343,77</b>	<b>6.082.655,23</b>	<b>18.963.269,66</b>	<b>308.377,95</b>	<b>148.246.646,61</b>

#### IV. Mapa geográfico de ventas

El gráfico de tipo **mapa de burbujas** representa la distribución geográfica de las ventas por ciudad. En este caso:

- El **tamaño de la burbuja** está determinado por el volumen de ventas.
- El **color** refleja el clúster del producto más vendido en esa ubicación.

Este visual permite a la empresa identificar regiones de alta y baja concentración de ventas, patrones geográficos de comportamiento comercial y posibles áreas de oportunidad para la expansión o la reorientación comercial. Además, incluye información adicional **cuando pasas el ratón por encima** de una de las burbujas, indicando:



## V. Gráfico de árbol (Tree Map): ventas por clúster

En la esquina superior derecha se presenta un gráfico de tipo **Tree Map**, que muestra las ventas totales agrupadas por clúster. El uso de este tipo de visualización permite:

- Comparar rápidamente el peso relativo de cada clúster dentro del total de ventas.
- Observar de forma jerárquica qué grupos de productos generan mayor rentabilidad o concentran mayor actividad comercial.




## VI. Gráfico de líneas con área sombreada: evolución mensual

La visualización situada en la parte inferior derecha representa la evolución mensual de las ventas para distintos años, usando múltiplos pequeños (small multiples) por año. Cada gráfico incluye:

- Una **línea de tendencia** mensual.
- Un **relleno inferior** para facilitar la lectura del comportamiento estacional.

Este gráfico permite comparar la estacionalidad de las ventas entre años de forma clara y facilita la detección de patrones o anomalías temporales. Resulta particularmente útil para la planificación de la producción o campañas comerciales.






## VII. Diagrama de anillos: top 5 clientes

Finalmente, en la parte inferior izquierda se ha añadido un gráfico de **anillos o donut** que muestra el porcentaje de ventas atribuido a los principales clientes. Su objetivo es identificar:

- Oportunidades de fidelización o segmentación de clientes con mayor valor.



## Integración y funcionalidad del conjunto

Todos los visuales están interconectados mediante los filtros y relaciones del modelo, lo que permite realizar un análisis multidimensional e interactivo. El diseño se ha optimizado para ofrecer una navegación intuitiva y una jerarquía visual clara, priorizando la información más relevante y facilitando el acceso a distintos niveles de detalle.

## 9. CONTRIBUCIÓN DEL DASHBOARD A LA TOMA DE DECISIONES Y ANÁLISIS DE RESULTADOS

La construcción de este cuadro de mando representa un paso fundamental para que IEBS Manufacturing avance hacia una gestión basada en datos (data-driven). A través de la explotación de los datos disponibles en el sistema ERP, la empresa puede por primera vez visualizar y analizar en profundidad el comportamiento de su catálogo de productos, su base de clientes, y la evolución temporal y geográfica de sus ventas. Esta capacidad analítica constituye una herramienta clave para mejorar la eficiencia comercial, productiva y logística.

### Impacto del dashboard en la gestión de producto

Gracias a la integración del modelo de inteligencia artificial basado en clustering, el cuadro de mando permite segmentar los productos en función de su **nivel de rotación y relevancia comercial**. Esta clasificación se incorpora a todas las visualizaciones y filtros, lo que posibilita:

- **Identificar productos de baja rotación** que generan un volumen marginal de ventas y que, sin embargo, pueden estar ocupando espacio en inventario o recursos productivos innecesarios.
- **Priorizar productos clave**, definidos por su alta facturación y su contribución recurrente al beneficio, como base para campañas de fidelización o planes de producción ajustados a la demanda.
- **Analizar el comportamiento intermedio** de los productos incluidos en el clúster de catálogo medio, para evaluar su evolución, potencial de crecimiento o necesidad de modificación.

Esta segmentación empodera a los responsables de producto y ventas para tomar decisiones informadas respecto a la optimización del catálogo, reducción de costes y mejora de la rentabilidad.

### Resultados destacados obtenidos a partir de los gráficos

El análisis visual del cuadro de mando permite extraer conclusiones relevantes sobre el comportamiento de la empresa:

- **Ventas por clúster:** se observa que el grupo de productos clasificados como "Catálogo medio" representa el mayor volumen de ventas globales, seguido por los productos de "Alta rotación". Sin embargo, los productos de "Baja rotación" suponen un porcentaje considerable, lo que sugiere la necesidad de evaluar su mantenimiento en el catálogo.
- **Distribución por tipo de producto:** en la tabla cruzada se aprecia que el grupo "Elaborado" concentra la mayor parte de las ventas dentro de todos los clústeres, lo que indica su papel central en la actividad de la empresa. Este hallazgo puede guiar decisiones de inversión en fabricación, mejora técnica o distribución asociada a esta categoría.
- **Geografía comercial:** el mapa interactivo muestra una alta concentración de ventas en el territorio nacional y en países vecinos de Europa Occidental. Esto permite detectar áreas geográficas con baja penetración comercial y abre posibilidades para explorar mercados infraexplotados.
- **Clientes principales:** el gráfico de anillos evidencia una fuerte concentración en pocos clientes (el cliente principal representa cerca del 50% de la facturación). Este dato alerta sobre una potencial dependencia comercial y sugiere desarrollar estrategias de diversificación o fidelización.
- **Evolución temporal:** los gráficos de ventas mensuales por año indican una relativa estabilidad en los volúmenes vendidos, con ligeras caídas en determinados meses del segundo semestre. Esta estacionalidad puede anticiparse mediante planificación operativa y comercial más ajustada.

### **Valor estratégico del dashboard**

Este cuadro de mando no es solamente una herramienta de visualización, sino un **sistema de soporte a la decisión empresarial**. Su impacto se manifiesta en varios niveles:

- A nivel táctico, permite optimizar campañas de venta, planificar producción e identificar productos con baja rentabilidad.

- A nivel estratégico, proporciona evidencias objetivas para rediseñar el catálogo, explorar nuevos mercados o priorizar segmentos clave.
- A nivel operativo, mejora la eficiencia de los equipos al ofrecer información accesible y en tiempo real, sin necesidad de recurrir a informes estáticos o extracción manual de datos.

## 10. CONCLUSIÓN

El desarrollo de este proyecto ha permitido demostrar cómo una empresa tradicional como IEBS Manufacturing puede avanzar de forma efectiva hacia un modelo de gestión basado en datos, apoyándose en herramientas de business intelligence, técnicas de análisis avanzado y procesos de transformación digital.

A través del diseño de un modelo de datos robusto, la integración de técnicas de inteligencia artificial (clustering) y la creación de un cuadro de mando personalizado en Power BI, se ha dado respuesta a un problema empresarial concreto: la necesidad de segmentar el catálogo de productos en función de su rotación, rentabilidad y comportamiento comercial. Esta segmentación ha permitido identificar productos clave, optimizar la cartera comercial y anticipar decisiones estratégicas sobre producción, inventario o eliminación de referencias.

El dashboard construido permite a los responsables de la empresa explorar la información de forma interactiva, aplicar filtros por tipo de producto, cliente, fecha o clúster, y acceder a indicadores clave como ventas, costes, beneficio, ticket medio y clientes únicos. Todo ello contribuye a mejorar la planificación operativa, reducir la dependencia de clientes concretos, localizar oportunidades de mercado y potenciar el uso estratégico de los datos.

A nivel metodológico, el proyecto ha puesto en práctica los conocimientos adquiridos durante el Máster en Data Analysis y Business Intelligence, integrando herramientas como SQL Server, Power BI, DAX, Python y técnicas de machine learning no supervisado. La experiencia adquirida refuerza la importancia de

combinar la visión técnica con el enfoque de negocio para generar valor real a partir de los datos.

Como líneas futuras de desarrollo, se plantea la posibilidad de extender el modelo analítico con nuevas fuentes de datos (producción, compras, almacén), incorporar modelos predictivos (forecasting de demanda o churn de clientes) y publicar el dashboard en el servicio Power BI Service para su consulta en tiempo real por parte del equipo directivo.